

Türkiye Geneli Konut Fiyatı Sınıflandırması: Sıfırdan NumPy MLP ve Elle Geri Yayılım

Berk Burhan Cesur

Öğrenci No: 230212023 · Ders: Veri Madenciliği · Öğretim Üyesi: Dr. Haydar Kılıç

Öz — Bu çalışmada, Türkiye genelindeki konut fiyatlarını üç sınıfa (Uygun, Orta, Pahalı) ayıran bir sınıflandırma sistemi geliştirilmiştir. Temel katkı, herhangi bir derin öğrenme kütüphanesi kullanılmadan yalnızca NumPy ile sıfırdan yazılan ve geri yayılım matematiğini elle uygulayan bir Çok Katmanlı Algılayıcı (CustomMLP) modelidir. Kaggle’den alınan 15.276 konut ilanından oluşan veri seti üzerinde kapsamlı ön işleme uygulanmış; CustomMLP, sklearn MLPClassifier ve Lojistik Regresyon modelleri karşılaştırmalı olarak değerlendirilmiştir. CustomMLP, Macro-F1 = 0.687 ve Accuracy = 0.685 ile sklearn MLP’yi (F1 = 0.672) geride bırakmıştır. ReLU aktivasyonu, Sigmoid’e kıyasla yaklaşık 2 kat hızlı yakınsama sağlamış; gradient checking ile matematiksel doğruluk teyit edilmiştir.

Anahtar Kelimeler: Konut Fiyatı Tahmini, MLP, Geri Yayılım, ReLU, Sınıflandırma, NumPy

1. GİRİŞ

Türkiye’de konut fiyatları son yıllarda hem yatırımcılar hem de alıcılar için kritik bir karar parametresi haline gelmiştir. Doğru fiyat segmentini tahmin edebilmek; konut politikaları, kişisel bütçe planlaması ve gayrimenkul yatırımları açısından büyük önem taşımaktadır.

Bu çalışmanın temel amacı, konut fiyatı sınıflandırmasını hazır kütüphanelere bağımlı kalmadan gerçekleştirmek ve böylece ileri besleme ağının matematiksel temellerini somut biçimde uygulamaktır. Bu doğrultuda NumPy ile sıfırdan yazılan CustomMLP modeli, zincir kuralına dayalı elle geri yayılım ile eğitilmiş ve gradient checking ile doğrulanmıştır.



Şekil 1: Proje kapak slaytı: Türkiye Geneli Konut Fiyatı Sınıflandırması.

2. VERİ SETİ VE ÖN İŞLEME

2.1. Veri Kaynağı

Veri seti, Kaggle platformundaki *Real Estate Prices in*

Turkey 2025 veri setinden elde edilmiştir. 15.276 konut ilanını ve 8 sütunu kapsamaktadır: İl, İlçe, Mahalle, Metrekare, Oda Sayısı, Satıcı Tipi, Tarih ve Fiyat.

2.2. Hedef Değişken

Fiyat sütunu yüzdelik dilimler kullanılarak üç sınıfa dönüştürülmüştür:

- **0 — Uygun:** 33. yüzdeliğin altı
- **1 — Orta:** 33.–66. yüzdelik arası
- **2 — Pahalı:** 66. yüzdeliğin üstü

2.3. Ön İşleme Pipeline

Veri ön işleme beş aşamadan oluşmaktadır: (1) eksik fiyat değerleri dropna ile kaldırıldı; diğer sütunlar SimpleImputer (median) ile dolduruldu; (2) yüzdelik dilim tabanlı etiketleme yapıldı; (3) kategorik değişkenler (İl, İlçe, Mahalle, Oda Sayısı, Satıcı Tipi) One-Hot Encoding ile sayısal forma çevrildi; (4) sayısal özellikler StandardScaler ile ($\mu = 0$, $\sigma = 1$) standartlaştırıldı; (5)



stratifiye örnekleme ile %80/%20 eğitim/test bölünmesi yapıldı.

Şekil 2: Veri seti ve ön işleme pipeline'ı.

3. MODEL MİMARİSİ

3.1. CustomMLP

CustomMLP, yalnızca NumPy kullanılarak sıfırdan yazılmıştır. Mimari aşağıdaki gibidir:

$$\text{Giriş}(563) \rightarrow H_1(64) \rightarrow H_2(32) \rightarrow \text{Çıkış}(3) \quad (1)$$

ReLU aktivasyonu kullanıldığında He başlatma, Sigmoid için Xavier başlatma otomatik olarak seçilmiştir. Sınıf dengesizliğinin gidermek amacıyla `class_weights` uygulanmıştır.

3.2. İleri Geçiş

$$Z_1 = X \cdot W_1 + b_1 \quad (2)$$

$$A_1 = \text{ReLU}(Z_1) \quad (3)$$

$$Z_2 = A_1 \cdot W_2 + b_2 \quad (4)$$

$$\hat{A} = \text{Softmax}(Z_2) \quad (5)$$

$$\mathcal{L} = -\frac{1}{N} \sum y \cdot \log(\hat{A}) \quad (6)$$



3.3. Geri Yayımlı – Zincir Kuralı

$$dZ_2 = (\hat{A} - Y) / N \quad (7)$$

$$dW_2 = A_1^T \cdot dZ_2, \quad db_2 = \sum dZ_2 \quad (8)$$

$$dW_1 = X^T \cdot dZ_1, \quad db_1 = \sum dZ_1 \quad (10)$$

$$W \leftarrow W - \text{lr} \cdot dW \quad (\text{SGD})$$

$$dZ_1 = (dZ_2 \cdot W_2^T) * \text{ReLU}'(Z_1) \quad (9)$$

Şekil 3: Model mimarisi ve geri yayılım matematiği.

4. DOĞRULAMA VE DENEYLER

4.1. Gradient Checking

Analitik türevler sayısal türevlerle karşılaştırılmış; tüm parametrelerde göreceli hata $< 10^{-10}$ bulunmuştur:

Tablo 1: Gradient checking sonuçları.

Parametre	Göreceli Hata
∂W_1	2.30×10^{-10}
∂b_1	1.20×10^{-10}
∂W_2	3.81×10^{-11}
∂b_2	1.01×10^{-11}
Overfitting	


testi: 10 örnekte 500 epoch eğitim sonunda kayıp ≈ 0.000018 'e düşmüş, geri yayılımın doğruluğu kanıtlanmıştır.

4.2. Deney 1 – ReLU vs Sigmoid

Tablo 2: Aktivasyon fonksiyonu karşılaştırması.

Aktivasyon	Macro-F1	Süre
ReLU	0.687	72 sn
Sigmoid	0.697	133 sn

Sigmoid minimal F1 üstünlüğü sağlamakla birlikte yakınsama süresi yaklaşık 2 kat uzundur. Pratik kullanımda ReLU tercih edilmektedir.



Şekil 4: Aktivasyon fonksiyonları karşılaştırması ve gradient checking sonuçları.

4.3. Deney 2 — Ağ Derinliği

Tablo 3: 1 vs 2 gizli katman karşılaştırması.


Mimari	Macro-F1	Loss
1 Gizli Katman (64→3)	0.693	0.577
2 Gizli Katman (64→32→3)	0.687	0.544

5. SONUÇLAR


5.1. Model Karşılaştırması

Tablo 4: Tüm modellerin karşılaştırması.

Model	F1	Acc	LL
CustomMLP ReLU	0.687	0.685	0.845
sklearn MLP	0.672	0.668	0.969
Lojistik Reg.	0.684	0.681	0.781




Şekil 5: A/B test sonuçları: epoch-loss eğrileri ve confusion matrix karşılaştırması.



Şekil 6: Tüm deneylerin Macro-F1 özeti.

CustomMLP, hazır kütüphane kullanmaksızın sklearn MLP'yi F1 ve Accuracy açısından geride bırakmıştır.


6. KEŞİFSEL VERİ ANALİZİ



Şekil 7: EDA: İllere göre fiyat dağılımı ve metrekafe-fiyat ilişkisi.

EDA bulguları: 15.276 ilan içinde Muğla en yüksek ortalama fiyata (7.44M TL) sahipken İstanbul ikinci sıradadır (6.04M TL). 3+1 oda tipi en yaygın kategorik değerdir. Metrekare-fiyat Pearson korelasyonu $r = 0.34$ olarak hesaplanmıştır.

6.1. Özellik Önemi



Şekil 8: Lojistik regresyon katsayılarına dayalı özellik önemi ve korelasyon matrisi.

Lojistik regresyon katsayıları incelendiğinde metrekaresinin (0.7135) en belirleyici özellik olduğu

görülmektedir. Bodrum, Muğla ve Marmaris gibi tatil bölgelerine ait coğrafi özellikler de fiyat sınıflandırmasında güçlü rol oynamaktadır.

Tablo 5: En önemli 5 özellik.

Özellik	Ortalama Katsayı
Metrekare	0.7135
İlçe_Bodrum	0.4727
Oda_Sayısı_2+0	0.4545
İl_Muğla	0.4253
İlçe_Marmaris	0.3375

7. TARTIŞMA

Matematiksel doğruluk: Gradient checking sonuçları ($< 10^{-10}$) ve overfitting testi, geri yayılım implementasyonunun doğruluğunu kesin biçimde kanıtlamaktadır.

ReLU vs Sigmoid: ReLU 2 kat hızlı yakınsama ile pratik üstünlüğünü ortaya koymuştur. Sigmoid minimal F1 üstünlüğü (+0.010) sağlasa da yakınsama süresi neredeyse iki katıdır.

Sınıflandırma gücü: $F1 \approx 0.69$ düzeyindeki performans, konut fiyatlarının doğrusal olmayan ve bölgesel dinamikler tarafından güçlü biçimde şekillendirildiğini göstermektedir. One-Hot Encoding sonrası 563 özelliikle çalışmak boyutsallık sorununu da beraberinde getirmektedir.

Coğrafi etki: Tatil bölgesi ilçelerinin özellik öneminde üst sıralarda yer alması, konut fiyatlarının salt metrekare veya oda sayısının ötesinde güçlü bir coğrafi bileşen taşıdığını ortaya koymaktadır.

8. GELECEK ÇALIŞMALAR

Daha derin mimari: 3–4 gizli katman ile dropout regularizasyonu eklenerek F1 skoru iyileştirilebilir.

Boyut indirgeme: PCA veya özellik seçimi ile 563 özellik azaltılabilir, eğitim hızı artırılabilir.

Hiperparametre optimizasyonu: Öğrenme hızı, batch size ve epoch sayısı için grid search veya Bayesian optimizasyon uygulanabilir.

Konum verileri: İl/ilçe bilgisinin ötesinde koordinat verileri ile coğrafi etkinin daha hassas modellenmesi mümkündür.

Zaman serisi: Tarih sütununun dönemsel bileşenlere ayrıştırılmasıyla fiyat trendleri tahmine dahil edilebilir.

9. SONUÇ

Sonuç & Kaynaklar	
Temel Bulgular	Kaynaklar (APA)
CustomMLP (NumPy, sferat) sklearn ile kıyaslanabilir: F1=0.687 vs sklearn 0.672 → hazır kütüphane olmadan gerçek başarımlar elde edildi.	[1] LeCun, Y., Bottou, L., Orr, G. B., & Müller, K. R. (2012). Efficient Backprop. In <i>Neural Networks: Tricks of the Trade</i> (2nd ed.). Springer.
ReLU, Sigmoid'a göre 2x hızlı yakınsadı (72 vs 133 it). Sigmoid F1'de minimal üstün (0.697 vs 0.687) ancak pratik kullanımda ReLU tercih edildi.	[2] He, K., Zhang, K., Ren, S., & Sun, J. (2015). Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. <i>ICCV</i> , 2015.
Gradient Checking: Tüm parametreler $< 1e-10$ hata. Overfitting testi: 10 örnekte loss $\rightarrow 0$. Matematiksel doğruluk kanıtlandı.	[3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). <i>Deep learning</i> (2nd ed.). MIT Press.
Özellik önemi: Metrekare (0.71) ve tatil bölgeleri (Muğla, Bodrum, Marmaris) sınıflandırmada belirleyici → coğrafi bağlam kritik.	[4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. <i>JMLR</i> , 12, 2825–2830.
Bölge Rilevansite sistemi (Akıne 14): 8/8'ya/ne7bölge gördüyle model gerçek dünya uygulamaya hazır.	[5] Glorot, X., & Bengio, Y. (2010). Understanding the difficulty of training deep feedforward neural networks. <i>AISTATS</i> .

Şekil 9: Temel bulgular ve sonuç özeti.

Bu çalışmada, Türkiye konut fiyatı sınıflandırması için yalnızca NumPy kullanılarak sıfırdan yazılan bir MLP modeli geliştirilmiştir. CustomMLP, Macro-F1 = 0.687 ve Accuracy = 0.685 ile hazır kütüphane kullanan sklearn MLP'yi (F1 = 0.672) geride bırakmıştır. Gradient checking ($< 10^{-10}$) ve overfitting testi ile matematiksel doğruluk teyit edilmiştir. ReLU aktivasyonu hız/F1 dengesi açısından tercih edilmiş; metrekare ve coğrafi özelliklerin fiyat sınıflandırmasındaki belirleyici rolleri EDA ile ortaya konmuştur.

KAYNAKÇA

Kaynaklar

- [1] Kaggle, “Real Estate Prices in Turkey 2025,” <https://www.kaggle.com>, 2025.
- [2] D. E. Rumelhart, G. E. Hinton, R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, pp. 533–536, 1986.
- [3] X. Glorot, Y. Bengio, “Understanding the difficulty of training deep feedforward neural networks,” *AISTATS*, 2010.
- [4] K. He et al., “Delving deep into rectifiers: Surpassing humanlevel performance on ImageNet classification,” *ICCV*, 2015.
- [5] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *JMLR*, vol. 12, pp. 2825–2830, 2011.